SPRAWOZDANIE

Zajęcia: Nauka o danych I

Prowadzący: prof. dr hab. Vasyl Martsenyuk

Laboratorium Nr 2	Dawid Klimek
Data 19.10.2024	Informatyka
Temat: "Praktyczne zastosowanie	II stopień, niestacjonarne,
podstawowych funkcji statystycznych	1semestr, gr.1A
w analizie danych"	
Wariant 6	

1. Polecenie: wariant 6 zadania

Oblicz podstawowe funkcje statystyczne używając zbiory danych z poprzedniego zajęcia

2. Opis programu opracowanego (kody źródłowe, rzuty ekranu)

[9]: import pandas as pd [10]: df = pd.read_csv('IHME_GBD_2019_CHEWING_TOB_1990_2019_DATA_Y2021M05D27.CSV',encoding='latin1') ⑥↑↓占무ⅰ measure_id measure_name location_id location_name sex_id sex_name age_group_id age_group_name rei_id rei_name metric_id metric_name year_id val 0 Chewing 1990 0.038740 5 Prevalence Global 1 Male 8 15 to 19 332 3 Rate Chewing Prevalence Global 15 to 19 332 1990 0.011356 Chewing 1 15 to 19 332 2 5 Prevalence Global Male 8 3 Rate 1991 0.039253 Prevalence Global Female 15 to 19 332 Rate Chewina 4 5 Prevalence 1 Global 1 Male 8 15 to 19 332 3 Rate 1992 0.039863 Chewing 350545 5 Prevalence 522 3 Both 27 Age standardized 332 3 2015 0.029518 Sudan Rate 522 Sudan Both 27 Age standardized 332 2016 0.029855 Chewing 350547 5 Prevalence 522 Sudan 3 Both 27 Age standardized 332 3 Rate 2017 0.029768 350548 522 Sudan 332 2018 0.029760 27 Age standardized 332 Chewing 5 Prevalence 3 3 2019 0.029752 350549 522 Sudan Both Rate 350550 rows × 16 columns < > [11]: df.dropna() measure_id measure_name location_id location_name sex_id sex_name age_group_id age_group_name rei_id rei_name metric_id metric_name year_id val Chewing 5 Prevalence Global Male 15 to 19 332 1990 0.038740 Rate Chewing Prevalence Global Female 15 to 19 332 Rate 1990 0.011356 Chewing 2 5 1 8 332 1991 0.039253 Prevalence Global Male 15 to 19 3 Rate Chewing Prevalence Global Female 15 to 19 332 1991 0.011516 4 1 1 Male 15 to 19 332 1992 0.039863 5 Prevalence Global 3 Rate tobacco 5 27 Age standardized 332 2015 0.029518 350545 Prevalence tobacco Chewina 350546 Prevalence 522 Sudan 3 Both 27 Age standardized 332 Rate 2016 0.029855 350547 5 Prevalence 522 Sudan 3 Both 27 Age standardized 332 3 Rate 2017 0.029768 tobacco Chewing 350548 Prevalence 522 Sudan Both 27 Age standardized 332 2018 0.029760 Chewing 350549 5 Prevalence 522 Sudan 3 Both 27 Age standardized 332 3 2019 0.029752 Rate tobacco 350550 rows × 16 columns <

```
[12]: ser = df['val']
                   0.011356
             0.039253
0.011516
0.039863
        350545 0.029518
350546 0.029855
350547 0.029768
350548 0.029760
350549 0.029752
        Name: val, Length: 350550, dtype: float64
[13]: # obliczanie średniej
[13]: 0.020178816871399226
[14]: #obliczanie mediany
[14]: 0.0048691325
[15]: #OdchyLenie standardowe
       np.std(ser)
[15]: 0.049593893684802264
       np.var(ser)
[16]: 0.00245955429081947
[17]: ser2 = df['lower']
[17]: 0 0.027147
1 0.007779
2 0.027608
3 0.007906
4 0.027800
       350545 0.024255
350546 0.024500
350547 0.024428
350548 0.024462
350549 0.024318
        Name: lower, Length: 350550, dtype: float64
        correlation = np.corrcoef(ser,ser2) [0,1]
       print(correlation)
        0.9780038085580645
[19]: #Kowariancja
       covariance = np.cov(ser,ser2) [0,1]
        covariance
[19]: 0.0016552467290792375
```

3. Wnioski

Wartości są bardzo zbliżone, operując na niskich wartościach, korelacja pomiędzy ser i ser 2 jest bardzo zbliżona do 1 co oznaczy że korelacja jest dodatnia i bardzo silna. Niska wartość wariancji świadczy o niskim rozrzucie danych.